

# Laborator 3: Rețele neurale

## 1 Motivație

- Capacitatea rețelelor neurale artificiale (RNA) de estimare a unei funcții pornind de la o mulțime de observații. Această abordare este utilă în aplicații în care complexitatea datelor sau a problemei nu permit determinarea manuală a funcției.
- Dorința de a înțelege modul în care funcționează creierul: RNA permit simularea calculului paralel realizat de neuroni și conexiunile dintre aceștia.
- Eficiența RNA folosind algoritmi de învățare inspirați de funcționalitatea creierului în rezolvarea unor probleme practice.

## 2 Definirea problemei

- Pornind de la o mulțime de date, denumită mulțime de antrenare, de forma,

$$S = \{(x^1, t^1), (x^2, t^2), \dots, (x^m, t^m)\} \quad (2.1)$$

unde  $x^i$  reprezintă un vector de caracteristici ale unui obiect (spre exemplu, constând în măsurători clinice), iar  $t^i$  o măsurătoare (variabilă de ieșire, etichetă, clasă) asociată obiectului, de obicei cantitativă (de exemplu, bursa de valori) sau nominală (precum, a avut un atac de cord/ nu a avut un atac de cord), pentru orice  $i = 1, \dots, m$ , RNA au ca scop prezicerea măsurătorii  $t$  asociate unui nou obiect, pe baza mulțimii de caracteristici ale obiectului reținute în vectorul  $x$ .

- Problema enunțată mai sus se numește de învățare supervizată datorită prezenței în mulțimea de antrenare a variabilei de ieșire, care facilitează procesul de învățare.
- În învățarea nesupervizată se cunosc vectorii de caracteristici asociați obiectelor ( $\{x^i, i = 1, \dots, m\}$ ), dar nu există măsurători privind etichetele corespunzătoare ( $\{t^i, i = 1, \dots, m\}$ ). Scopul algoritmilor este de a descrie modul de organizare sau de grupare a datelor.

### Algoritm 1: Structura unui algoritm de învățare

Intrare	Mulțimea de date de antrenare, constând în măsurători asupra unor caracteristici ale unei mulțimi de obiecte (de exemplu, indivizi) și etichetele/clasele corespunzătoare fiecărui obiect
Procesul	Pe baza datelor de intrare se construiește un model de predicție (numit în engleză “learner”) care ne va permite să prezicem etichetele/clasele unor noi obiecte necunoscute a priori, pe baza vectorilor de caracteristici ai acestora.
Ieșire	Eticheta/clasa asociată unui nou obiect, necunoscut a priori

## 3 Aplicații din lumea reală

- Prezicerea posibilității ca un pacient spitalizat din cauza unui infarct să aibă un nou infarct. Abilitatea de prezicere se bazează pe măsurători clinice asupra pacientului analizat.
- Estimarea bursei de valori pentru următoarele 6 luni, pe baza unor măsurători privind performanțele unor companii și date economice.
- Filtrarea mail-urilor de tip “spam”.
- Recunoașterea numerelor dintr-un cod ZIP scrise de mână pornind de la o imagine digitală.
- Identificarea factorilor de risc care ar conduce la apariția cancerului pe baza unor variabile clinice și demografice.
- Estimarea cantității de glucoză din sânge a unei persoane având diabet pornind de la spectrul de absorbție (infraroșu) al sângelui pacientului.

### Exemplu: Aplicația de recunoaștere a caracterelor în Matlab

```
[alphabet target] = prprob();  
noisyJ = alphabet(:,10) + 0.2*randn(35,1);  
plotchar(noisyJ);
```

## 4 Reprezentarea rețelelor neurale artificiale în Matlab

Vezi fișierul “Laborator 3 part 2.pdf”

## Bibliografie

- [1] T. Hastie, R. Tibshirani, J. Friedman (2008), *The Elements of Statistical Learning*, Springer
- [2] Yashpal Singh, Alok Singh Chauhan, *Neural Networks in Data Mining*, Journal of Theoretical and Applied Information Technology ([www.jatit.org](http://www.jatit.org))