

Laborator 4: Utilizarea unei rețele cu un singur neuron (rețea de tip perceptron) pentru rezolvarea problemelor de clasificare liniar separabile.

1 Definirea modelului de învățare

- Se dă mulțimea de antrenare, de forma,

$$S_m = \{ (\mathbf{x}^1, d^1), (\mathbf{x}^2, d^2), \dots, (\mathbf{x}^m, d^m) \} \quad (1.1)$$

unde \mathbf{x}^i este un vector de intrare al perceptronului/rețelei de forma

$$\mathbf{x}^i = [x_1^i, x_2^i, \dots, x_n^i]^T,$$

iar $d^i \in \{-1, 1\}$ reprezintă măsurătoarea de ieșire (eticheta, clasa) asociată intrării \mathbf{x}^i , pentru orice $i = 1, \dots, m$. Se definește vectorul

$$\mathbf{X}^i = [(\mathbf{x}^i)^T, 1]^T \quad (1.2)$$

ca fiind o extindere a vectorului \mathbf{x}^i , prin adăugarea componentei $x_{n+1}^i = 1$ la vectorul de intrare \mathbf{x}^i căreia i se asociază o pondere numită bias (deplasare).

- Reprezentarea grafică a modelului perceptronului poate fi vizualizată în Figura 1.
- Se notează cu $\mathbf{w} = [w_1, \dots, w_n, w_{n+1}]^T$ vectorul conținând parametrii modelului perceptronului, reprezentat în Figura 1.
- Relația intrare \mathbf{x} /ieșire \mathbf{y} este dată de $y = \text{sgn}(\mathbf{X}^T \mathbf{w})$, unde $\mathbf{X} = [\mathbf{x}^T, 1]^T$.
- Obiectivul este de a determina parametrii w_1, \dots, w_n, w_{n+1} ai perceptronului astfel încât pentru un nou vector de intrare \mathbf{x} , ieșirea \mathbf{y} a perceptronului să estimeze corect eticheta/clasa reală a acestuia. Dacă acest obiectiv este realizat pentru vectorii din mulțimea de antrenare spunem că perceptronul clasifică corect mulțimea de antrenare.




Figura 1: Reprezentarea grafică a modelului perceptronului

Atenție: în această reprezentare grafică “ \mathbf{x} ” este “ \mathbf{X} ”, unde $\mathbf{X} = [\mathbf{x}^T, 1]^T$

2 Algoritmul de învățare al lui Rosenblatt

2.1 Detalii teoretice premergătoare dezvoltării algoritmului de învățare

- A găsi un perceptron care să clasifice corect mulțimea de antrenare înseamnă a determina un vector \mathbf{w}^* care să satisfacă relațiile:

$$\begin{cases} (\mathbf{X}^k)^T \mathbf{w}^* > 0, & \text{dacă } d^k = 1 \\ (\mathbf{X}^k)^T \mathbf{w}^* < 0, & \text{dacă } d^k = -1 \end{cases} \quad (2.1)$$

pentru $k = 1, \dots, m$.

- Mulțimea punctelor \mathbf{x} care satisfac ecuația $\mathbf{X}^T \mathbf{w}^* = 0$ ($\mathbf{X} = [\mathbf{x}^T, 1]^T$) formează un hiperplan în \mathbb{R}^n . Deci, a găsi o soluție \mathbf{w}^* a sistemului de mai sus înseamnă a determina un hiperplan care separă spațiul intrărilor $\{\mathbf{x}^k, k = 1, \dots, m\}$, în două semiplane, unul conținând mulțimea punctelor $\{\mathbf{x}^k | d^k = 1, k = 1, \dots, m\}$, iar celălalt mulțimea punctelor $\{\mathbf{x}^k | d^k = -1, k = 1, \dots, m\}$.

2.2 Regula de învățare a lui Rosenblatt

Pornind de la ipoteza că mulțimea de antrenare este liniar separabilă, se dezvoltă următoarea regulă de învățare (a lui Rosenblatt), având ca scop determinarea soluției \mathbf{w}^* care verifică relațiile (2.1):

$$\begin{cases} \mathbf{w}^1 & \text{arbitrar} \\ \mathbf{w}^{k+1} = \mathbf{w}^k + d^i \mathbf{X}^i, & \text{dacă } d^i \neq y^i, i = (k-1) \bmod m+1 \\ \mathbf{w}^{k+1} = \mathbf{w}^k, & \text{altfel} \end{cases} \quad (2.2)$$

Indicele superior k indică iterația la care se actualizează vectorul de ponderi \mathbf{w} .

2.3 Pașii algoritmului de învățare al lui Rosenblatt

Algoritm 1: Algoritmul de învățare al lui Rosenblatt

Intrare	Mulțimea de date de antrenare $S_m = \{(\mathbf{x}^1, d^1), (\mathbf{x}^2, d^2), \dots, (\mathbf{x}^m, d^m)\}$
Pas 1	Se inițializează componentele vectorului de ponderi $\mathbf{w} = [w_1, \dots, w_n, w_{n+1}]$ cu valori aleatoare uniform distribuite în intervalul $(0, 1)$. Repetă Pas 2 pentru un număr fixat de epoci, maxEpochs
Pas 2	Pentru fiecare punct $i = 1, \dots, m$ din mulțimea de antrenare execută iterativ/succesiv Pas 3 – Pas 5
Pas 3	$n = (\mathbf{X}^i)^T * \mathbf{w}$, unde $\mathbf{X}^i = [(\mathbf{x}^i)^T, 1]^T$ și $\mathbf{w} = [w_1, \dots, w_n, w_{n+1}]^T$
Pas 4	Dacă $n > 0$ atunci $y = 1$; altfel $y = -1$
Pas 5	Dacă $d^i \neq y$ atunci $\mathbf{w} = \mathbf{w} + d^i * \mathbf{X}^i$
Ieșire	Vectorul de ponderi \mathbf{w}

În cele ce urmează sunt prezentate câteva observații privind algoritmul de învățare al lui Rosenblatt descris în Algoritm 1:

- La început, se selectează vectorul ponderilor, notat \mathbf{w}^1 aleator, apoi utilizând succesiv perechile (\mathbf{x}^i, d^i) , $i \in 1, \dots, m$ din mulțimea de antrenare se actualizează vectorul ponderilor \mathbf{w}^{k+1} de la pasul $k+1$, unde $i = (k-1) \bmod m+1$, pentru a găsi soluția \mathbf{w}^* care clasifică corect mulțimea de antrenare.

- De obicei, sunt necesare mai multe cicluri (epoci), adică parcurgerea în întregime a mulțimii de antrenare, până când eroarea, determinată de diferențele dintre ieșirile perceptronului/rețelei și etichetele corecte, va fi zero.
- Problema de clasificare descrisă mai sus poate fi rezolvată folosind un singur perceptron, adică există vectorul \mathbf{w}^* dacă și numai dacă mulțimea de antrenare este liniar separabilă (i.e. există un hiperplan care să clasifice corect punctele din mulțimea de antrenare).
- Din punctul de vedere al liniar separabilității, funcțiile booleene OR (disjuncția) și AND (conjuncția) corespund unor probleme liniar separabile, pe când funcția XOR (disjuncția exclusivă) corespunde unei probleme neliniar separabile.

3 Aplicație

Se consideră punctele din plan $\mathbf{x}^1 = (1, 1)^T$, $\mathbf{x}^2 = (-1, 1)^T$, $\mathbf{x}^3 = (-1, -1)^T$ și $\mathbf{x}^4 = (1, -1)^T$ împărțite în 2 clase liniar separabile (de exemplu $\{\mathbf{x}^1, \mathbf{x}^4\}$ din clasa codificată cu 1 și $\{\mathbf{x}^2, \mathbf{x}^3\}$ din clasa codificată cu -1).

Se cere să se determine parametrii perceptronului capabil să clasifice corect în cele două clase datele indicate mai sus.

Indicație: Modelul perceptronului corespunzător aplicației este ilustrat în Figura 2.




Figura 2: Modelul perceptronului pentru vectori de intrare bidimensionali

Bibliografie

- [1] D. Enăchescu (2003), *Elements of Statistical Learning. Applications in Data Mining*, Padova University Press
- [2] T. Hastie, R. Tibshirani, J. Friedman (2008), *The Elements of Statistical Learning*, Springer