

* În orașul B prob. a priori de a avea loc o crimă este invers proporțională cu nr. de bărbați adulți din orașul B. Într-un proces care este probabilizat să auză să fie găsit vinovat știind că la locul crimei a fost găsit o mostră de ADN care coincide cu ADN-ul auzatului. Probabilitatea ca dovada ADN-ului să coincide este de 10^{-6} iar în oraș sunt $5 \cdot 10^4$ bărbați adulți.

Sol.

$G = "$ ev. că auzatul este vinovat "

$E = "$ ev. ca ADN-ul auzatului să coincidă cu moștră prelevată "

$$\Rightarrow P(G) = \frac{1}{5 \cdot 10^4} \quad \text{și} \quad P(E/G) = \frac{1}{10^6}$$

• $P(E/G) = 1$ întrucât auzatul este unușiul atenu
ale 2 ADN-uri coincid.

• Sist. complet de ev. $\{G, \bar{G}\} \Rightarrow P(\bar{G}) = 1 - P(G)$

$$\text{• Te Bayes} \quad P(G/E) = \frac{P(G) P(E/G)}{P(G) P(E/G) + P(\bar{G}) P(E/\bar{G})}$$

$$= 0,95238185941$$

* Într-o urnă se află n bile. Sunt posibile $\binom{n+1}{2}$ ipoteze asupra numărului de bile albe din urnă. Se notează cu H_i ipoteza că în urnă sunt i bile albe. Presupunem că toate ipotezele sunt egal probabile. Din urnă se extrage k întâmplător 0 bile care sînt albe. Care este ipoteza cu cea mai mare probabilitate a posteriori? Justificați.

Sol

• Sînt. complet de evenimente $\{H_i\}_{i=0}^n$

• $P(H_i) = \frac{1}{n+1}$, $i = 0, \dots, n$

• $B = \{0, \dots, n\}$ - extrageri unei bile albe

• (form. R. Bayes) $P(H_i|B) = \frac{P(H_i)P(B|H_i)}{\sum_{j=0}^n P(H_j)P(B|H_j)}$

• $\Rightarrow P(H_i|B) = \frac{\frac{1}{n+1} \cdot \frac{1}{n}}{\frac{1}{n(n+1)} \cdot \sum_{j=0}^n j} = \frac{2i}{n(n+1)}$

• $\max_i P(H_i|B) = \frac{2n}{n(n+1)} = \frac{2}{n+1}$; corespunde $i = n$

* (Semnale în regimul gaussian) Fie ρ_0 și $\rho_1 \in \mathbb{R}$ date și $Z \sim N(0, \sigma^2)$ cu σ^2 date. Fie $P[Y=1] = 1/2$ și fie $X = \begin{cases} \rho_0 \text{ dacă } Y=0 \\ \rho_1 \text{ dacă } Y=1 \end{cases}$. Constante.

* puncte de decizie bayesiene și calculati L^* eroare la decizie minimă. $\rho_0 = -1, \rho_1 = 1$ și $\sigma^2 = 1$.

Sol.

$$g^*: \mathbb{R} \rightarrow \{0, 1\} \text{ cu } g^*(x) = \begin{cases} 1 & \text{dacă } q(x) > 1/2 \\ 0 & \text{în rest} \end{cases}$$

$$\text{unde } q(x) = \frac{P f_0(x)}{P f_0(x) + (1-P) f_1(x)}, \quad P = P[Y=1],$$

f_0 și f_1 d.p. a $X|Y=0$ respectiv $X|Y=1$

$$\Rightarrow g(x) = \begin{cases} 1 & \text{dacă } P f_1(x) > (1-P) f_0(x) \\ 0 & \text{în rest} \end{cases}$$

$$\Rightarrow g^*(x) = \begin{cases} 1 & \text{dacă } 2(\rho_1 - \rho_0)x + \rho_0^2 - \rho_1^2 > 0 \\ 0 & \text{în rest} \end{cases} \Rightarrow g^*(x) = \begin{cases} 1 & \text{dacă } x > \frac{\rho_1 + \rho_0}{2} \\ 0 & \text{în rest} \end{cases}$$

$$L^* = \int_{\mathbb{R}} \min(q(x), 1-q(x)) f(x) dx = \frac{1}{2} - \frac{1}{\sigma} \int_{\mathbb{R}} |f_1(x) - f_0(x)| dx$$

cu val. integrale
luate din Tabelul
lin $\Phi(0,1)$

$$= \frac{1}{2} - \int_0^1 f(x) dx = 0,158655$$

$$= \frac{1}{\sqrt{2\pi}} \int_0^{\frac{x}{\sigma}} e^{-\frac{t^2}{2}} dt$$

$$= P f_1(x) + (1-P) f_0(x)$$

Haykin - Neural Networks and Learning Machines (1999) 69-75

MLP (maximum a posteriori) estimator = \hat{w} (regularized least squares)

in modelled by regular linear

(provided by slide-wise lecture 36)

in ipitz regularization gaussian

SLR

- linear regression model: preliminary motivation
- an unknown stochastic environment produce an regressor $\underline{x} \in \mathbb{R}^n$
 - the response of the supervisor is $y \in \mathbb{R}$
 - the LM propose a linear regression model, i.e.

$$\hat{y} = \sum_{j=1}^n w_j x_j + \epsilon$$

under w_1, \dots, w_n ~~fixed~~ with a set of fixed, but unknown parameters

meaning that the environment is stationary

The additive term ϵ , representing the expected error of the model, accounts for our ignorance about the environment.

$$\hat{y} = \sum_{j=1}^n \hat{w}_j x_j + \epsilon \quad \text{on } \underline{w} \in \mathbb{R}^n$$

$$\hat{y} = \underline{x}^T \underline{w} + \epsilon$$

The loss function

- Sum of squared errors $\sum_{i=1}^n (y_i - \underline{x}_i^T \underline{w})^2 = \ell(y, h(\underline{x}))$

$$\ell(\underline{w}) = \frac{1}{2} \sum_{i=1}^n (y_i - \underline{x}_i^T \underline{w})^2$$

$$\hat{\underline{w}}_{MLE} = \min_{\underline{w}} \ell(\underline{w}) = \min_{\underline{w}} (\underline{y} - \underline{X} \underline{w})^T (\underline{y} - \underline{X} \underline{w})$$

$$= \min_{\underline{w}} \|\underline{y} - \underline{X} \underline{w}\|^2 = \min_{\underline{w}} \|\underline{y} - \underline{X} \underline{w}\|^2$$

\Rightarrow

- Regularized least squared error

$$\hat{\underline{w}}_{RLS} = \min_{\underline{w}} \left[\ell(\underline{w}) + \frac{\lambda}{2} \|\underline{w}\|^2 \right] = \min_{\underline{w}} \left[\ell(\underline{w}) + \frac{\lambda}{2} \underline{w}^T \underline{w} \right]$$

statistic ridge regression

Neural Net

weights decay $(1/\eta)$

• Maximum a posteriori estimator

Assumption 1: Statistical independence and identical distribution (i.i.d)
~~Assumption 1~~ The n examples, constituting the training sample, are statistically independent and identically distributed

Assumption 2: The \underline{D}_x is gaussian, i.e. the environment, responsible for generation of the training sample \underline{g} , is Gaussian distributed. More specifically $\underline{g}_i \sim N(0, \sigma^2)$ $P(\underline{g}_i) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp(-\frac{\underline{g}_i^2}{2\sigma^2})$, $i=1, \dots, n$

Assumption 3 The environment is stationary, which means that the parameters with \underline{w} is fixed, but unknown, throughout the trials of the experiment.

$$\Rightarrow E[\underline{y}_i] = \underline{x}_i^T \underline{w}, \quad i=1, \dots, n$$

$$\text{var}[\underline{y}_i] = E[(\underline{y}_i - E[\underline{y}_i])^2] = \text{var}[\underline{x}_i^T \underline{w} + \underline{g}_i] = \text{var}[\underline{g}_i] = \sigma^2$$

Given the Bayes of distribution

$$\Rightarrow P(\underline{w} | \underline{y}, \underline{X}) = \frac{P(\underline{w}) P(\underline{y} | \underline{w}, \underline{X})}{P(\underline{y} | \underline{X})}$$

$$\propto P(\underline{w}) P(\underline{y} | \underline{w}, \underline{X}) \quad \text{likelihood function}$$

$$P(\underline{w}) = \prod_{i=1}^n P(y_i | \underline{x}_i, \underline{w}) = \prod_{i=1}^n \frac{1}{\sigma} \exp\left(-\frac{1}{2\sigma^2} (y_i - \underline{x}_i^T \underline{w})^2\right)$$

Bayes $P(\underline{w} | \underline{y}, \underline{X}) = \underbrace{\text{argmax}_{\underline{w}}}_{\text{MAP}} P(\underline{w}) P(\underline{y} | \underline{w}, \underline{X})$

Ass 2 $\Rightarrow P(\underline{w} | \underline{y}, \underline{X}) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{1}{2\sigma^2} (\underline{y} - \underline{X}^T \underline{w})^2\right)$

Ass 1 $\Rightarrow P(\underline{w} | \underline{y}, \underline{X}) = \prod_{i=1}^n P(\underline{w} | \underline{y}_i, \underline{x}_i) = \frac{1}{(2\pi\sigma^2)^{n/2}} \prod_{i=1}^n \exp\left(-\frac{1}{2\sigma^2} (y_i - \underline{x}_i^T \underline{w})^2\right)$

likelihood function

sem 2

$$P(\underline{w} | \underline{Y}, X) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \underline{x}_i^T \underline{w})^2\right)$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \underbrace{(\underline{Y} - X^T \underline{w})^T (\underline{Y} - X^T \underline{w})}_{\epsilon(\underline{w})}\right]$$

$$\Rightarrow \ln P(\underline{w} | \underline{Y}, X) = -\frac{1}{2\sigma^2} \epsilon(\underline{w}) - \frac{n}{2} \ln(2\pi\sigma^2)$$

The only other source of information that remains to be accounted for is that contained in the prior $P(\underline{w})$. Looking for more specifically, the P elements of the weight vector \underline{w} are themselves assumed to be i.i.d. gaussian elements, i.e.

$$P(w_j) = \frac{1}{\sqrt{2\pi\sigma_w^2}} \exp\left(-\frac{w_j^2}{2\sigma_w^2}\right) \quad j=1, \dots, p$$

$$\Rightarrow P(\underline{w}) = \prod_{j=1}^p P(w_j) = \frac{1}{(2\pi\sigma_w^2)^{p/2}} \exp\left[-\frac{1}{2\sigma_w^2} \sum_{j=1}^p w_j^2\right]$$

$$= \frac{1}{(2\pi\sigma_w^2)^{p/2}} \exp\left[-\frac{1}{2\sigma_w^2} \underbrace{\|\underline{w}\|^2}_{\|\underline{w}\|^2}\right]$$

independent

$$\Rightarrow \ln P(\underline{w}) = -\frac{1}{2\sigma_w^2} \|\underline{w}\|^2 - \frac{p}{2} \ln(2\pi\sigma_w^2)$$

$$\text{Cum } P(\underline{w} | \underline{Y}, X) \propto P(\underline{w}) P(\underline{Y} | \underline{w}, X) =$$

$$\ln P(\underline{w} | \underline{Y}, X) \propto \ln P(\underline{w}) + \ln P(\underline{Y} | \underline{w}, X)$$

$$\Rightarrow \hat{\underline{w}}_{MAP} = \underset{\underline{w}}{\text{argmax}} \left[-\frac{1}{2\sigma^2} \epsilon(\underline{w}) - \frac{1}{2\sigma_w^2} \|\underline{w}\|^2 \right] = \underset{\underline{w}}{\text{min}} \left[\epsilon(\underline{w}) + \frac{1}{2} \left(\frac{\sigma^2}{\sigma_w^2} \right) \|\underline{w}\|^2 \right]$$

in the version

Obs

- ① The Bayesian paradigm for parameter estimation, rooted in the Bayes Theorem and exemplified by the MAP estimator, exploits all the conceivable information about the parameter vector ω . In contrast, the ML estimator lies only on the likelihood function, ignoring the prior. \Rightarrow overfitting, and poor generalization.
- ② The ML estimator relies solely on the observation model (y, x) and may therefore lead to a nonunique solution. To enforce uniqueness and stability on the solution, the prior $p(w)$ has to be incorporated into the formulation of the estimator. This is done in the RML estimator or automatically in the MAP estimator.

* Găsiți formula lui $\underline{w}^* \in \mathbb{R}^{n+1}$, prezenta min perceptor ADA LINE, a minimizat, pe o mulțime de antrenare date, SSE regularizat a termenul $\frac{\lambda}{2} \|\underline{w}\|^2$ cu $\lambda > 0$ dat.

Soluție

- Fi $\{(x_i, t_i)\}_{i=1, m}$, $\underline{x}_i \in \mathbb{R}^n$, $t_i \in \mathbb{R}$, mulțime de antrenare
- Fi $y(\underline{x}) = \underline{w}^T \cdot \underline{x}$ iar \underline{w} perceptor ADA LINE unde $\underline{x} = [1, \underline{x}]^T$ și $\underline{w} = [w_0, w_1, \dots, w_n]^T$.
- Fi $\underline{x} = [\tilde{x}_1, \dots, \tilde{x}_m]$ matrice $(m+1) \times m$ a exemplare și $\underline{t} = [t_1, \dots, t_m]^T$ vectorul $m \times 1$ al etichetelor
- Fi de cost în paradigma SSE regularizat a fi:

$$J(\underline{w}) = \frac{1}{2} \sum_{i=1}^m (t_i - y(\tilde{x}_i))^2 + \frac{\lambda}{2} \|\underline{w}\|^2$$

(A. simplifica în cele ce urmează vom renunța la "n" x "n" -)

Se observă că

$$J(\underline{w}) = \frac{1}{2} (t - \tilde{X} \underline{w})^T (t - \tilde{X} \underline{w}) + \frac{\lambda}{2} \underline{w}^T \cdot \underline{w}$$

$$\Rightarrow \nabla J(\underline{w}) = -\tilde{X}^T (t - \tilde{X} \underline{w}) + \lambda \underline{w}$$

$$\Rightarrow \nabla J(\underline{w}) = 0 \Rightarrow (\tilde{X}^T \underline{w}) + \lambda \underline{w} = \tilde{X}^T t$$

$$[(\tilde{X}^T) + \lambda \mathbb{I}_{m+1}] \underline{w} = \tilde{X}^T t$$

$$\Rightarrow \underline{w}^* = [(\tilde{X}^T) + \lambda \mathbb{I}_{m+1}]^{-1} \cdot \tilde{X}^T t$$

Exercitiu: Scenariile comentate într-un joc spectacol în care un

un premiu este esențial în spatele unei dutei cele trei câștigate.

Veteranul primului din alegere ~~scenariu~~ câștigă câștig. După
- u ale ale câștigă, dar înainte ca se să fie ridicată,
prezentatorul vede o dute - câștigă 2 câștiguri, ~~scenariu~~
o scenă goală și va trebui să decidă dacă dute să se va schimba
opțiunea - înainte pentru câștigul rămas. Care este strategia
optimă: păstrarea sau schimbarea opțiunii câștig?

scenariu = câștig

alegere
în dute

decide dacă

maxim

Problema: $\Omega = \{a_1, a_2, a_3\} \times \{d_1, d_2, d_3\} \times \{m_1, m_2, m_3\}$.

ai

$|\Omega| = 12 \neq$ $\Omega = \{(a_i, d_j, m_k) \mid i \neq j, j \neq k\}$.

$= \{(a_1, d_2, m_1), (a_1, d_2, m_3), (a_2, d_3, m_1), \dots$

$\}$

Notăm cu A_i evenimentul să aleg a_i .

De comentat prezentatorul să decidă sau A

M_i evenimentul să meargă să fie în spatele câștigului A .

Fără a pierde generalitatea, analizăm cazul în care aleg $a_{11} = câștig = 1$
să decidă sau câștig = 2.

Prezentatorul știe A_i și m_i .

$$P(M_2 | A_1 \cap D_2) = 0.$$

$$P(M_3 | A_1 \cap D_2) = \frac{P(M_3 \cap A_1 \cap D_2)}{P(A_1 \cap D_2)} = \frac{P(D_2 | M_3 \cap A_1) \cdot P(M_3 \cap A_1)}{P(A_1 \cap D_2)} = \frac{\frac{1}{2} \cdot \frac{1}{3} \cdot \frac{1}{3}}{\frac{1}{6}} = \frac{1}{3}$$

$$P(M_3 | A_1 \cap D_2) = \frac{P(D_2 | M_3 \cap A_1) \cdot P(M_3 \cap A_1)}{\frac{1}{6}} = \frac{1 \cdot \frac{1}{3} \cdot \frac{1}{3}}{\frac{1}{6}} = \frac{2}{3}$$